



SAÉ:

ÉCHANTILLONNAGE ET ESTIMATION

Fait par Imane Kharbouche et Quentin Chirol

2024-2025



Introduction :

Cette SAE a pour objectif d'analyser l'incertitude ainsi que la précision liée à l'estimation d'une caractéristique au sein d'une population, en s'appuyant sur l'utilisation d'un intervalle de confiance issu de méthodes d'échantillonnage. Dans le cadre de cette analyse, la population étudiée correspond à celle de la région Occitanie. Plus précisément, notre étude s'est concentrée sur le nombre d'habitants dans cette région.

Par ailleurs, nous avons travaillé sur une enquête portant sur la pratique sportive des étudiants. Cette enquête, réalisée à partir d'un fichier de données nommé *EnqueteSportEtudiant2024.csv*, nous a permis d'analyser les comportements et habitudes liés à l'activité physique en fonction de différentes caractéristiques sociodémographiques et de mode de vie. À l'aide de tests du χ^2 d'indépendance et du calcul du V de Cramer, nous avons évalué la force des liaisons entre la variable sport (pratique ou non d'une activité physique) et plusieurs variables qualitatives comme le sexe, le niveau d'études, le statut d'alternant, ou encore les habitudes de santé ou d'alimentation. L'objectif était d'identifier quelles variables présentent une liaison statistiquement significative avec la pratique du sport, et de mesurer l'intensité de ces liaisons.

Dans un premier temps, nous avons réalisé un échantillonnage à l'aide du logiciel R, en appliquant un tirage aléatoire simple avec des probabilités équivalentes (supposant que chaque commune possède un nombre identique d'habitants). Ensuite, nous avons mis en œuvre un échantillonnage stratifié, fondé sur les quartiles et les déciles de la population.

Les valeurs estimées obtenues ont ensuite été confrontées aux données réelles afin de mesurer la précision des résultats et d'en faire l'analyse.

Enfin, indépendamment des précédentes données, un test du khi-deux a été effectué via R dans le but de tester l'indépendance entre certaines variables. Il s'agissait ici d'évaluer si la prime d'assurance automobile pouvait être influencée par des facteurs comme la Marque, l'Ancienneté du véhicule, la Puissance fiscale, la Catégorie ou encore la Formule d'assurance choisie.

Partie 1.1 : Echantillonnage aléatoire simple

Pour tirer des échantillonnages aléatoires on a utilisé une bibliothèque « *sampling* » qui tire des lignes aléatoires dans le data frame donné puis une autre bibliothèque « *stringr* » qui permet de corriger les lignes d'affectueuse dans le data frame.

```
#installer les packages des librairies si elles n'existent pas
install.packages("stringr")
install.packages("sampling")

# charger les données depuis le fichier csv
library(stringr)
library(sampling)
```

Nous avons tout d'abord pris le fichier content toutes les communes de France : « *population_française_Communes.csv* » et nous l'avons chargé dans R. On a filtré se tableau

pour garder toutes les communes d'Occitanie puis on a gardé les champs qui ne seront utiles pour les échantillonnages : ("Code.département", "Commune", "Population.totale")

```
#####
# Partie 1 : Estimation du nombre d'habitants d'une région de France
#####

# charger les données depuis le fichier csv
table <- read.csv("population_francaise_communes.csv", sep = ";", dec = ",", header = TRUE, fileEncoding = "latin1")
# Filtrer les données pour obtenir uniquement les communes de la région Occitanie
donnees <- subset(table, Nom.de.la.region == "occitanie", select = c("Code.département", "Commune", "Population.totale"))
```

Puis on affiche les première ligne de la table données grâce à Head(données):

	Code.département	Commune	Population.totale
2817	09	Aigues-Juntas	58
2818	09	Aigues-Vives	654
2819	09	L' Aiguillon	390
2820	09	Albiès	120
2821	09	Aleu	130
2822	09	Alliat	56

La table U est un vecteur qui contient toutes les communes d'Occitanie, elle vient du data frames données. Ou on a pris la colonne Commune.

```
# Supprimer les espaces dans les chiffres de la population et convertir en numérique
donnees$Population.totale <- as.numeric(str_remove_all(donnees$Population.totale, " "))

#variables U avec les communes
U <- donnees$Commune
head(U)
U
```

Pour calculer le nombre de commune, on a utilisé la fonction length(longueur) qui permet de donner la taille du vecteur U

```
# calculer le nombre total de communes dans U
N<- length(U)
N
```

Dans la région d'Occitanie ont à 4454 communes.

Pour calculer le nombre total d'habitant ont utilisé la fonction sum(somme) qui permet de faire la somme de toutes les valeurs dans un vecteur dans ce cas donnees\$Population.totale

```
# calculer le nombre total d'habitants de la région Occitanie
T <- sum(donnees$Population.totale)
T
```

La population totale dans la région de l'Occitanie est de 6097513.

Pour la question de 4-9, Nous avons cherché à estimer la population de la région Occitanie à l'aide d'un échantillonnage aléatoire simple. Pour cela, nous avons sélectionné un échantillon de n = 100 communes, extrait de la base de données initiale "donnee1", et constitué une nouvelle table appelée "donnee2", contenant deux colonnes : "commune" et "population.total".

À partir de cet échantillon, nous avons calculé la moyenne du nombre d'habitants par commune, qui s'est élevée à 1 000 habitants. En multipliant cette moyenne par le nombre total de communes dans la région, nous avons obtenu une estimation de la population régionale. Un intervalle de confiance (IC) à 95 % a été construit autour de cette estimation, permettant d'indiquer une fourchette dans laquelle la population réelle est censée se situer avec une probabilité de 95 %.

Lors de notre premier essai, l'intervalle obtenu était [2 584 060 : 11 811 954]. La population réelle des Occitanie (6 097 513 habitants) se situait bien à l'intérieur de cet intervalle, ce qui valide notre estimation. Cependant, la marge d'erreur était importante, à savoir habitants, ce qui réduit la précision de l'estimation.

Afin d'évaluer la robustesse de notre méthode, nous avons répété l'expérience dix fois à l'aide d'une boucle for, consignait à chaque fois les résultats dans un tableau pour les comparer. Ces itérations ont mis en évidence une grande variabilité des estimations, en fonction des communes tirées au sort. En effet, un échantillon contenant majoritairement des communes très peuplées ou, au contraire, peu peuplées, influence fortement le résultat. Cela illustre l'une des limites de l'échantillonnage aléatoire simple, surtout dans le cas d'une population hétérogène.

Pour conclure, nous avons synthétisé les résultats dans un fichier CSV, comprenant :

- Les populations estimées,
- Les marges d'erreur,
- Les intervalles de confiance,
- Ainsi que la population réelle de la région.

```
# Définir la taille de l'échantillon
n <- 100

# Répéter le processus d'échantillonnage, d'estimation et de calcul d'IDC pour plusieurs échantillons
nombre_echantillons <- 100
resultats <- data.frame(PopulationEst = numeric(nombre_echantillons),
  marge = numeric(nombre_echantillons),
  IDC = character(nombre_echantillons),
  populationreel = numeric(nombre_echantillons))

for (i in 1:nombre_echantillons) {
  # Échantillonnage
  E <- sample(U, n)

  # Sélection des données d'échantillon
  donnees1 <- donnees[donnees$Commune %in% E, ]
  donnees2 <- subset(donnees1, select = c(Commune, Population.totale))

  # Moyenne de l'échantillon
  xbar <- mean(donnees2$Population.totale)

  # Intervalle de confiance
  idcmoy <- t.test(donnees2$Population.totale)$conf.int

  # Estimation totale
  T_est <- N * xbar

  # IDC pour le total
  idcT <- idcmoy * N

  # Marge d'erreur
  marge <- (idcT[2] - idcT[1]) / 2


  # Stocker les résultats
  resultats[i, ] <- list(T_est, marge, paste(round(idcT[1]), "-", round(idcT[2])), r)
}

# Valeurs
xbar
idcmoy
T_est
idcT
marge

# Écriture des résultats dans un fichier csv
write.csv2(resultats, file = "C:\\Users\\ikharbou\\OneDrive - Université de Poitiers\\BUT\\S2\\SAE\\ECHANTILLONNAGE\\sae\\resultat.csv", row.names = FALSE)
```

Tableau et graphique récapitulatif de la première partie :

Echantillon	population estimé	marge	idc	population réelle
1	3607067,698	992743,5817	2614324 - 4599811	6097513
2	7895669,429	4583320,484	3312349 - 12478990	6097513
3	3556103,797	1123770,737	2432333 - 4679875	6097513
4	3522304,182	1493131,91	2029172 - 5015436	6097513
5	4271462,793	1721449,784	2550013 - 5992913	6097513
6	4331218,067	1530692,985	2800525 - 5861911	6097513
7	4707057,526	2554027,162	2153030 - 7261085	6097513
8	3970462,625	1393016,493	2577446 - 5363479	6097513
9	4013286,383	1244932,583	2768354 - 5258219	6097513
10	6807235,737	3343492,587	3463743 - 10150728	6097513



Afin d'améliorer la précision de nos estimations, nous avons envisagé de recourir à un échantillonnage stratifié. Cette méthode consiste à diviser la population en sous-groupes homogènes (ou strates) et à tirer des échantillons au sein de chaque strate en respectant leurs proportions dans la population totale. Dans le contexte des Hauts-de-France, cela reviendrait à sélectionner 100 communes en veillant à représenter fidèlement la répartition réelle entre petites et grandes villes.

Partie 1.2 : Echantillonnage aléatoire simple

À la suite de nos premiers résultats et constats, nous avons comparé l'échantillonnage aléatoire simple avec un échantillonnage stratifié, en utilisant les mêmes données et la même méthodologie générale. L'objectif était d'améliorer la représentativité de l'échantillon et, par conséquent, la précision de l'estimation.

Dans un premier temps, nous avons utilisé les quartiles de la table "données" pour diviser les communes en quatre strates selon leur population :

- Strate 1 : communes de moins de 137 habitants
- Strate 2 : communes entre 138 et 308 habitants
- Strate 3 : communes entre 309 et 1369 habitants
- Strate 4 : communes de plus de 5030202 habitants

Chaque strate contenait environ un quart des communes totales :

- Strate 1 : 742 communes
- Strate 2 : 1483 communes
- Strate 3 : 1111 communes
- Strate 4 : 1118 communes

Par la suite, nous avons affiné la stratification en utilisant les déciles, ce qui nous a permis de créer dix strates. Cette approche plus fine a conduit à des résultats plus précis, car elle tient mieux compte de l'hétérogénéité des tailles de population entre communes.

Dans l'étape suivante, nous avons procédé à un tirage aléatoire de 100 communes, réparties équitablement entre les quatre strates (25 communes par strate). À partir de ce tirage, nous avons constitué un nouveau data frame regroupant le nom des communes sélectionnées ainsi que leur nombre d'habitants, servant de base à une nouvelle estimation de la population de la région Occitanie.

```
#
# Partie 1.2 : Echantillonnage aléatoire stratifié
#
# Echantillonnage stratifié
quantiles<-summary(donnees$Population.totale)
quantiles

# strates : <137, entre 137 et 308, entre 308 et 1369 entre 1369 et 503020, plus de 503020
donnees$Strate=cut(donnees$Population.totale, breaks=c(0,137, 308,1369,503020), labels=c(1,2,3,4))
donneesstrat=donnees[,c("Commune", "Population.totale", "Strate")]
head(donneesstrat)

# effectif des strates
data = donneesstrat[order(donneesstrat$Strate), ]
Nh=table(data$Strate)
Nh
sum(Nh)

# Tirage d'un échantillon stratifié de taille n=100
n=100
nh=c(25,25,25,25)
# Répéter le processus d'échantillonnage, d'estimation et de calcul d'IDC pour plusieurs échantillons
nombre_echantillons <- 10
```

Après avoir établi nos strates, nous avons procédé au tirage de quatre échantillons par strate, puis calculé leurs moyennes et variances respectives. Une fois ces calculs terminés, nous avons également déterminé la moyenne et la variance globale des strates. Ces analyses nous ont ensuite permis d'estimer la population des Occitanie.

```

for (i in 1:nombre_echantillons) {
  # sondage strat (sans remise dans les strates)
  st = strata(data, stratanames = c("Strate"), size = nh, method = "srswr")
  data1=getdata(data, st)
  head(data1)
  length((data1$Commune))

  # Poids des strates
  gh=nh/N
  gh
  # taux de sondage des strates
  fh=nh/Nh
  fh

  #dÉFINIR LES QUATRES STRATES
  ech1=data1[data1$Strate==1, ]
  ech1
  ech2=data1[data1$Strate==2, ]
  ech3=data1[data1$Strate==3, ]
  ech4=data1[data1$Strate==4, ]

  # Moyennes des 4 \ 'echantillons
  m1=mean(ech1$Population.totale)
  m2=mean(ech2$Population.totale)
  m3=mean(ech3$Population.totale)
  m4=mean(ech4$Population.totale)

  # Variances des 4 \ 'echantillons
  var1=var(ech1$Population.totale)
  var2=var(ech2$Population.totale)
  var3=var(ech3$Population.totale)
  var4=var(ech4$Population.totale)

```

Nous avons ensuite réalisé une première estimation de la population régionale à partir de notre échantillon stratifié, obtenant un résultat de 6 050 034 habitants, à comparer à la population réelle d'Occitanie, qui est de 6 097 513 habitants.

Pour évaluer la précision de cette estimation, nous avons construit un intervalle de confiance (IC) à 95 %, censé contenir la véritable valeur du paramètre estimé, c'est-à-dire le nombre réel d'habitants. Cet intervalle, calculé à partir de notre échantillon de 100 communes réparties selon les strates, indique qu'il y a 95 % de probabilité que la valeur réelle soit comprise dans cette fourchette.

Lors de ce premier essai, l'intervalle obtenu était [3 882 399; 6 875 966], ce qui inclut bien la population réelle de la région (6 097 513 habitants). Nous pouvions donc affirmer, avec un niveau de confiance de 95 %, que notre estimation était cohérente.

Pour approfondir l'analyse et mieux interpréter ces résultats, nous avons répété l'expérience dix fois, en consignait chaque estimation dans un tableau comparatif. Cela nous a permis d'observer la variabilité des résultats et de mieux comprendre les effets de la stratification sur la précision des estimations.

Afin de pouvoir interpréter au mieux ces résultats, nous avons également répété l'opération suivante dix fois et nous avons inscrit nos résultats dans un tableau afin de pouvoir les comparer.

```

# Moyenne gl'ennale (des 3 \echant r\enns)
xbarst= (Nh[1]*m1 + Nh[2]*m2 + Nh[3]*m3 + Nh[4]*m4)/N

# estimation de la variance de xbarst
varxbarst= ((gh[1])^2)*(1-fh[1])*var1/(nh[1]) + ((gh[2])^2)*(1-fh[2])*var2/(nh[2]) + ((gh[3])^2)*(1-fh[3])*var3/(nh[3]) + ((gh[4])^2)*(1-fh[4])*var4/(nh[4])


# idc pour mu \a 95%
alpha=0.05
binf= xbarst - qnorm(1-alpha/2)*sqrt(varxbarst)
bsup= xbarst + qnorm(1-alpha/2)*sqrt(varxbarst)
idcmoy=c(binf, bsup)
# estim du total T
Tstr= N*xbarst
Tstr
# Estimation par IDC du total T
binf= idcmoy[1]*N
bsup= idcmoy[2]*N
idct=c(binf, bsup)
idct

# marge d'erreur
marge=(idct[2]-idct[1])/2
marge
resultatsstrat[i, ] <- list(Tstr, marge, paste(idct[2], "-", idct[1]), T)

```

Tableau et graphique récapitulatif de la deuxième partie :

Echantillon	population estimé	marge	idc	population réelle
1	4608165,48	1204608,409	5812773.8892632 - 3403557.0707368	6097513
2	5820072,72	3446476,649	9266549.36882846 - 2373596.07117154	6097513
3	3583046,4	670918,0284	4253964.42837772 - 2912128.37162228	6097513
4	13681288,72	17048216,49	30729505.2107878 - -3366927.77078776	6097513
5	5014605,08	1080985,62	6095590.69980033 - 3933619.46019967	6097513
6	3953357,8	685138,1193	4638495.91929823 - 3268219.68070178	6097513
7	3541193,28	718854,2727	4260047.55267795 - 2822339.00732205	6097513
8	4543252,12	1011589,583	5554841.70337511 - 3531662.53662489	6097513
9	4529062,92	1198618,365	5727681.28480901 - 3330444.55519099	6097513
10	5036942,28	1409623,506	6446565.78628374 - 3627318.77371625	6097513



Stratification par déciles :

Nous avons ensuite affiné notre méthode en divisant les communes selon les déciles de leur population, afin d'obtenir dix strates plus précises. Voici les seuils de population définissant chaque strate :

- Strate 1 : communes de moins de 72 habitants
- Strate 2 : de 73 à 113 habitants
- Strate 3 : de 114 à 164 habitants
- Strate 4 : de 165 à 226 habitants
- Strate 5 : de 227 à 308 habitants
- Strate 6 : de 309 à 444 habitants
- Strate 7 : de 445 à 667 habitants
- Strate 8 : de 668 à 1141 habitants
- Strate 9 : de 1142 à 2452 habitants
- Strate 10 : plus de 503020 habitants

Cette division permettait de constituer dix groupes équilibrés en nombre de communes, ce qui améliore la représentativité de l'échantillon :

- Strate 1 : 444 communes
- Strate 2 : 445 communes
- Strate 3 : 445 communes
- Strate 4 : 445 communes
- Strate 5 : 445 communes
- Strate 6 : 445 communes
- Strate 7 : 446 communes
- Strate 8 : 446 communes
- Strate 9 : 446 communes
- Strate 10 : 448 communes

Nous avons ensuite procédé à un tirage aléatoire de 100 communes, soit 10 communes par strate, afin d'effectuer une estimation plus précise de la population des Hauts-de-France. Ce tirage a permis de créer un nouveau data frame contenant le nom des communes sélectionnées ainsi que leur nombre d'habitants, servant de base à notre nouvelle estimation.

```
#On compose 10 strates à partir des déciles

# calcul des déciles
deciles <- quantile(donnees$Population.totale , probs = seq(0.1, 0.9, by = 0.1))
deciles

# strates :
donnees$Strate=cut(donnees$Population.totale, breaks=c(0,72.3, 113., 164.0, 226.0 , 308.0, 444.0, 667.3, 1141.4, 2425.2, 503020 ), labels=c(1,2,3,4,5,6,7,8,9,10))
donneesStrat=donnees[,c("Commune", "Population.totale", "Strate")]
head(donneesStrat)

# effectif des strates
data = donneesStrat[order(donneesStrat$Strate), ]
Nh=table(data$Strate)
Nh
sum(Nh)

# Tirage d'un 'échantillon stratifié' de taille n=100
n=100
nh=c(10,10,10,10,10,10,10,10,10,10)
# Répéter le processus d'échantillonnage, d'estimation et de calcul d'IDC pour plusieurs échantillons
nombre_echantillons <- 10

resultatsStrat <- data.frame(PopulationEst = numeric(nombre_echantillons),marge = numeric(nombre_echantillons),IDC = character(nombre_echantillons),populationreel = T)
```

Une fois les strates établies, nous avons procédé au tirage aléatoire de dix échantillons par strate. Pour chacun de ces échantillons, nous avons calculé la moyenne et la variance de la population. Ces résultats nous ont ensuite permis de déterminer la moyenne et la variance globale sur l'ensemble des strates.


À partir de ces données, nous avons pu réaliser une première estimation de la population d'Occitanie, que nous avons évaluée à 8 067 551 habitants, contre une valeur réelle de 6 097 513 habitants.

Afin d'évaluer la fiabilité de cette estimation, nous avons construit un intervalle de confiance (IC) à 95 %, destiné à contenir avec une forte probabilité la véritable valeur du paramètre estimé. Calculé à partir de notre échantillon stratifié de 100 communes, l'IC obtenu lors de ce premier essai était de [1 679 563 ; 14 455 539]. La population réelle étant bien comprise dans cet intervalle, nous pouvions donc affirmer avec 95 % de confiance que notre estimation était conforme.

Pour mieux analyser la robustesse de cette méthode, nous avons répété l'opération dix fois, consignant systématiquement les résultats dans un tableau comparatif, ce qui nous a permis d'évaluer la stabilité des estimations obtenues via l'échantillonnage stratifié.

Tableau et graphique récapitulatif de la deuxième partie :

Echantillon	population estimé	marge	idc	population réelle
1	4343536	936751,21	5280287.21015996 - 3406784.78984004	6097513
2	4979712	1384102,51	6363814.5088761 - 3595609.4911239	6097513
3	4397987,5	1002030,81	5400018.30888086 - 3395956.69111914	6097513
4	5146982,4	1372591,66	6519574.064397 - 3774390.735603	6097513
5	4609774	846723,56	5456497.55955292 - 3763050.44044708	6097513
6	4190872,9	566091,43	4756964.32962784 - 3624781.47037216	6097513
7	5110230,4	815635,623	5925866.02282253 - 4294594.77717747	6097513
8	8650012,9	5488980,54	4138993.4419 - -6838967.6419	6097513
9	4080825,1	1003910,74	5084735.83640753 - 3076914.36359247	6097513
10	4676037,6	1027489,31	5703526.91476451 - 3648548.28523549	6097513



Conclusion :

Dans notre étude, l'échantillonnage stratifié s'est révélé être la méthode la plus adaptée, car il prenait en compte les disparités entre les différents sous-groupes de la population. Cette

méthode a permis une représentation équilibrée de chaque strate au sein de l'échantillon, ce qui a considérablement amélioré la précision des estimations.

Contrairement à l'échantillonnage aléatoire simple qui est plus rapide à mettre en œuvre et bien adapté aux populations homogènes mais l'échantillonnage stratifié offre une vision plus fine et plus fidèle de la réalité, surtout dans des contextes où la population est hétérogène.

Bien que cette méthode exige davantage de préparation, notamment l'identification des strates et la collecte d'informations préalables, ses avantages en termes de représentativité sont indiscutables.

Cela dit, il convient de relativiser ces résultats : malgré l'amélioration apportée par la stratification, les estimations ne permettent pas encore de reproduire avec exactitude la population réelle. Une stratification plus fine, par exemple en centiles, aurait pu renforcer encore davantage la fiabilité de nos estimations.

Partie 1.2 : Enquête Sport

Annexe R :

#Question 1 :

```
#installer les packages des librairies si elles n'existent pas
```

```
install.packages("stringr")
```

```
install.packages("sampling")
```

```
# Charger les données depuis le fichier csv
```

```
library(stringr)
```

```
library(sampling)
```

```
#####
```

```
# Partie 1 : Estimation du nombre d'habitants d'une région de France
```

```
#####
```

```
# Charger les données depuis le fichier CSV
```

```
table <- read.csv("population_francaise_communes.csv", sep = ";", dec = ",", header =  
TRUE, fileEncoding = "latin1")
```

```
# Filtrer les données pour obtenir uniquement les communes de la région Occitanie  
donnees <- subset(table, Nom.de.la.region == "Occitanie", select = c("Code.département",  
"Commune", "Population.totale"))
```

```
# Supprimer les espaces dans les chiffres de la population et convertir en numérique  
donnees$Population.totale <- as.numeric(str_remove_all(donnees$Population.totale, " "))
```

```
head(donnees)
```

#Question 2 :

```
#Variables U avec les communes
```

```
U <- donnees$Commune
```

```
head(U)
```

```
U
```

```
# Calculer le nombre total de communes dans U
```

```
N <- length(U)
```

```
N
```

#Question 3 :

```
# Calculer le nombre total d'habitants de la région Occitanie
```

```
T <- sum(donnees$Population.totale)
```

```
T
```

```
# Définir la taille de l'échantillon
```

```
n <- 100
```

```
# Répéter le processus d'échantillonnage, d'estimation et de calcul d'IDC pour plusieurs échantillons
```

```
nombre_echantillons <- 100
```

```
resultats <- data.frame(PopulationEst = numeric(nombre_echantillons),  
                        marge = numeric(nombre_echantillons),  
                        IDC = character(nombre_echantillons),  
                        populationreel = numeric(nombre_echantillons))
```

```
for (i in 1:nombre_echantillons) {
```

```
  # Échantillonnage
```

```
  E <- sample(U, n)
```

```
  head(E)
```

#Question 4 :

```
# Sélection des données d'échantillon
```

```
donnees1 <- donnees[donnees$Commune %in% E, ]
```

```
donnees2 <- subset(donnees1, select = c(Commune, Population.totale))
```

```
head(donnees2)
```

#Question 5 :

```
# Moyenne de l'échantillon
```

```
xbar <- mean(donnees2$Population.totale)
```

```
xbar
```

```
# Intervalle de confiance
```

```
idcmoy <- t.test(donnees2$Population.totale)$conf.int
```

```
idcmoy
```

#Question 6 :

```
# Estimation totale
```

```
T_est <- N * xbar
```

```
T_est
```

```
# IDC pour le total
```

```
idcT <- idcmoy * N
```

```
idcT
```

```
# Marge d'erreur
```

```
marge <- (idcT[2] - idcT[1]) / 2
```

marge

```
# Stocker les résultats
resultats[i, ] <- list(T_est, marge, paste(round(idcT[1]), "-", round(idcT[2])), T)
}

# Écriture des résultats dans un fichier CSV write.csv2(resultats, file = "resultat.csv",
row.names = FALSE)
```

#Partie 2 ----1:

```
#
# Partie 1.2 : Echantillonnage aléatoire stratifié
#
```

```
#Echantillonnage stratifié
quantiles<-summary(donnees$Population.totale)
quantiles
```

#2:

```
# strates : <137, entre 137 et 308,entre 308 et 1369 entre 1369 et 503020, plus de 503020
donnees$Strate=cut(donnees$Population.totale, breaks=c(0,137, 308,1369,503020),
labels=c(1,2,3,4))
donneesstrat=donnees[,c("Commune", "Population.totale", "Strate")]
head(donneesstrat)

# effectif des strates
data = donneesstrat[order(donneesstrat$Strate), ]
Nh=table(data$Strate)
Nh
sum(Nh)
```

#3:

```
# Tirage d'un échantillon stratifié de taille n=100
n=100
nh=c(25,25,25,25)
# Répéter le processus d'échantillonnage, d'estimation et de calcul d'IDC pour plusieurs
échantillons
nombre_echantillons <- 10
```

```
resultatsstrat <- data.frame(PopulationEst = numeric(nombre_echantillons),marge =
numeric(nombre_echantillons),IDC = character(nombre_echantillons),populationreel = T)
```

#4:

```
for (i in 1:nombre_echantillons) {
  # sondage strat (sans remise dans les strates)
  st = strata(data, stratanames = c("Strate"), size = nh, method = "srswr")
  data1=getdata(data, st)
  head(data1)
  length((data1$Commune))

  # Poids des strates
  gh=Nh/N
  gh
  # taux de sondage des strates
  fh=nh/Nh
  fh

  #dEFINIR LES QUATRES STRATES
  ech1=data1[data1$Strate==1, ]
  ech1
  ech2=data1[data1$Strate==2, ]
  ech3=data1[data1$Strate==3, ]
  ech4=data1[data1$Strate==4, ]

  # Moyennes des 4 \echantillons
  m1=mean(ech1$Population.totale)
  m2=mean(ech2$Population.totale)
  m3=mean(ech3$Population.totale)
  m4=mean(ech4$Population.totale)

  # Variances des 4 \echantillons
  var1=var(ech1$Population.totale)
  var2=var(ech2$Population.totale)
  var3=var(ech3$Population.totale)
  var4=var(ech4$Population.totale)
```

#5:

```
# Moyenne gl'en\erale (des 3 \echant r\eunis)
Xbarst= (Nh[1]*m1 + Nh[2]*m2 + Nh[3]*m3 + Nh[4]*m4)/N

# estimation de la variance de Xbarst
varXbarst= ((gh[1])^2)*(1-fh[1])*var1/(nh[1]) + ((gh[2])^2)*(1-fh[2])*var2/(nh[2])
+((gh[3])^2)*(1-fh[3])*var3/(nh[3]) + ((gh[4])^2)*(1-fh[4])*var4/(nh[4])
```

```
# idc pour mu \a 95%
alpha=0.05
binf = Xbarst - qnorm(1-alpha/2)*sqrt(varXbarst)
bsup = Xbarst + qnorm(1-alpha/2)*sqrt(varXbarst)
idcmoy=c(binf, bsup)
```

#6:

```
# marge d'erreur
marge=(idcT[2]-idcT[1])/2
marge
resultatsstrat[i, ] <- list(Tstr, marge, paste(idcT[2], "-", idcT[1]), T)
}

# Écriture des résultats dans un fichier CSV
write.csv2(resultatsstrat, file = "resultat des strates3.csv", row.names = FALSE)
```

#Partie 1 ---2:

```
# Calcul des déciles
deciles <- quantile(donnees$Population.totale , probs = seq(0.1, 0.9, by = 0.1))
deciles

# strates :
donnees$Strate=cut(donnees$Population.totale, breaks=c(0,72.3, 113., 164.0, 226.0 ,
308.0, 444.0, 667.3, 1141.4, 2425.2, 503020 ), labels=c(1,2,3,4,5,6,7,8,9,10))
donneesStrat=donnees[,c("Commune", "Population.totale", "Strate")]
head(donneesStrat)

# effectif des strates
data = donneesStrat[order(donneesStrat$Strate), ]
Nh=table(data$Strate)
Nh
sum(Nh)

# Tirage d'un \echantillon stratifi\e de taille n=100
n=100
nh=c(10,10,10,10,10,10,10,10,10,10)
# Répéter le processus d'échantillonnage, d'estimation et de calcul d'IDC pour plusieurs
échantillons
nombre_echantillons <- 10

resultatsStrat <- data.frame(PopulationEst = numeric(nombre_echantillons),marge =
numeric(nombre_echantillons),IDC = character(nombre_echantillons),populationreel = T)
```



```

for (i in 1:nombre_echantillons) {
  # sondage strat (sans remise dans les strates)
  st = strata(data, stratanames = c("Strate"), size = nh, method = "srswr")
  data1=getdata(data, st)
  head(data1)
  length((data1$Commune))

  # Poids des strates
  gh=Nh/N
  gh
  # taux de sondage des strates
  fh=nh/Nh
  fh

  #dEFINIR LES QUATRES STRATES
  ech1=data1[data1$Strate==1, ]
  ech1
  ech2=data1[data1$Strate==2, ]
  ech3=data1[data1$Strate==3, ]
  ech4=data1[data1$Strate==4, ]
  ech5=data1[data1$Strate==5, ]
  ech6=data1[data1$Strate==6, ]
  ech7=data1[data1$Strate==7, ]
  ech8=data1[data1$Strate==8, ]
  ech9=data1[data1$Strate==9, ]
  ech10=data1[data1$Strate==10, ]

  # Moyennes des 10 \echantillons
  m1=mean(ech1$Population.totale)
  m2=mean(ech2$Population.totale)
  m3=mean(ech3$Population.totale)
  m4=mean(ech4$Population.totale)
  m5=mean(ech5$Population.totale)
  m6=mean(ech6$Population.totale)
  m7=mean(ech7$Population.totale)
  m8=mean(ech8$Population.totale)
  m9=mean(ech9$Population.totale)
  m10=mean(ech10$Population.totale)

  # Variances des 10 \echantillons
  var1=var(ech1$Population.totale)
  var2=var(ech2$Population.totale)
  var3=var(ech3$Population.totale)
  var4=var(ech4$Population.totale)
  var5=var(ech5$Population.totale)
  var6=var(ech6$Population.totale)
  var7=var(ech7$Population.totale)
  var8=var(ech8$Population.totale)
  var9=var(ech9$Population.totale)
  var10=var(ech10$Population.totale)

```

```

# Moyenne g\'en\'erale (des 3 \'echant r\'eunis)
Xbarst= (Nh[1]*m1 + Nh[2]*m2 + Nh[3]*m3 + Nh[4]*m4+ Nh[5]*m5+ Nh[6]*m6+ Nh[7]*m7+
Nh[8]*m8+ Nh[9]*m9+ Nh[10]*m10)/N

# estimation de la variance de Xbarst
varXbarst= ((gh[1])^2)*(1-fh[1])*var1/(nh[1]) + ((gh[2])^2)*(1-fh[2])*var2/(nh[2])
+((gh[3])^2)*(1-fh[3])*var3/(nh[3]) + ((gh[4])^2)*(1-fh[4])*var4/(nh[4])+((gh[10])^2)*(1-
fh[10])*var10/(nh[10])+((gh[5])^2)*(1-fh[5])*var5/(nh[5])+((gh[6])^2)*(1-
fh[6])*var6/(nh[6])+((gh[7])^2)*(1-fh[7])*var7/(nh[7])+((gh[8])^2)*(1-
fh[8])*var8/(nh[8])+((gh[9])^2)*(1-fh[9])*var9/(nh[9])

# idc pour mu \'a 95%
alpha=0.05
binf = Xbarst - qnorm(1-alpha/2)*sqrt(varXbarst)
bsup = Xbarst + qnorm(1-alpha/2)*sqrt(varXbarst)
idcmoy=c(binf, bsup)
# estim du total T
Tstr= N*Xbarst
Tstr
# Estimation par IDC du total T
binf = idcmoy[1]*N
bsup= idcmoy[2]*N
idcT=c(binf, bsup)
idcT

# marge d\'erreur
marge=(idcT[2]-idcT[1])/2
marge
resultatsStrat[i, ] <- list(Tstr, marge, paste(idcT[2], "-", idcT[1]), T)

}

# \'ecriture des r\'esultats dans un fichier CSV
write.csv2(resultatsStrat, file = "resultat des 10 strates.csv", row.names = FALSE)

```

#Partie 2:

#2:

```

#####
# Partie 2 : Traitement de donn\'ees d'enqu\ete
#####

# Importation du fichier CSV
enquete_sport <- read.csv("C:\\Users\\likharbou\\OneDrive - Universit\'e de
Poitiers\\BUT1\\S2\\SAE\\ECHANTILLONNAGE\\sae\\EnqueteSportEtudiant2024.csv",
      sep = ";", dec = ",", header = TRUE, encoding = "latin1")

```

#3:

```
# Affichage des 6 premières lignes
head(enquete_sport)
n <- nrow(enquete_sport)
cat("Nombre d'observations :", n, "\n")
```

#4:

```
# Variables qualitatives à tester contre "sport"
vars <- c("sexe", "deptformation", "niveau", "alternant", "bourse",
         "logement", "fumer", "alimentation", "sante", "sportavant", "reussite")
```

#5:

#6:

#7:

#8:

